

# Медиана Кемени в задаче ранжирования и определения критической массы экспертов

Григорьев Алексей Дмитриевич

Московский физико-технический институт  
Физтех-школа прикладной математики и информатики  
Кафедра интеллектуальных систем

Москва, 2021

# Постановка задачи

## Дано

$\mathcal{D} = \{\mathbf{x}_i\}_{i=1}^n$ ,  $\mathbf{x}_i \in \mathbb{R}^k$  — вектор экспертных оценок,  $n$  — число объектов,  $k$  — число экспертов.

## Статистические предположения о данных

$\mathcal{R} = \{\mathbf{r}_j\}_{j=1}^k = \mathcal{D}^T$ , где  $\mathbf{r}_j \in \mathbb{R}^n$  — вектор, задающий ранжирование объектов  $j$ -ым экспертом,

$\mathcal{R} \stackrel{i.i.d.}{\sim} \mathcal{D}$ , где  $\mathcal{D}$  — фиксированное распределение, с конечным мат.ожиданием:  $\exists \mathbb{E}\mathcal{D}$ .

## Задачи

- Построить интегральный индикатор.
- Определить оптимальное число экспертов: построить процедуру принятия решения о достаточности текущего числа экспертов.

# Метод Кемени-Янга (медиана Кемени)

## Отношение частичного порядка

Для рейтинга  $\mathbf{r}_l$ ,  $\forall l = \overline{1, k}$  водится матрица попарных сравнений

$$\mathbf{A}^l = \begin{bmatrix} a_{11}^l & \dots & a_{1n}^l \\ \vdots & \ddots & \vdots \\ a_{n1}^l & \dots & a_{nn}^l \end{bmatrix}, a_{ij}^l = \begin{cases} 1, & r_{li} > r_{lj} \text{ (т.е. } x_{il} \succ x_{jl}) \\ 0, & \text{не сравнимы или равны} \\ -1, & r_{li} < r_{lj} \text{ (т.е. } x_{il} \prec x_{jl}) \end{cases}$$

*Пропуск* объекта в рейтинге соответствует его несравнимости.

## Расстояния на основе попарных сравнений

- Расстояние между парой рейтингов  $\mathbf{r}_l, \mathbf{r}_m$ :

$$d(\mathbf{r}_l, \mathbf{r}_m) = \sum_{i=1}^n \sum_{j=1}^n |a_{ij}^l - a_{ij}^m|$$

- Расстояние от рейтинга  $\mathbf{r}$  до мн-ва рейтингов  $\mathcal{R} = \{\mathbf{r}_l\}_{l=1}^k$ :

$$d(\mathbf{r}, \mathcal{R}) = \sum_{l=1}^k d(\mathbf{r}, \mathbf{r}_l)$$

# Метод Кемени-Янга (медиана Кемени)

## Медиана Кемени

*Медиана Кемени* для выборки рейтингов  $\mathcal{R}$  определяется как решение задачи оптимизации:

$$\mathbf{r}^* = \arg \min_{\mathbf{r}} d(\mathbf{r}, \mathcal{R}), \text{ где}$$

$\mathbf{r}$  — перестановка ранжирования.





*Интегральный индикатор*  $\mathcal{I}_i$  объекта  $i$  через медиану Кемени

$$\mathcal{I}_i = -r_i^*$$

## Свойства

- *частичный* порядок  $\Rightarrow \exists$  устойчивость к *пропускам*;
- NP-hard  $\Rightarrow$  алгоритм полного перебора всех перестановок;

# Результаты: сравнения рейтингов



## Предложения

- Метод устойчив к пропускам, медиана Кемени существует для произвольной выборки рейтингов.  
Чрезмерность числа пропусков определяется спецификой конкретной задачи и интерпретацией результата.
- Альтернативно может быть рассмотрен ансамбль других методов построения рейтинга и произведено сравнение с предложенным методом на предмет согласованности.  
Критерий сравнения — ранговое расстояние Кендалл-тау.

# Оптимальное число экспертов

## Принятие решения при пошаговом добавлении экспертов

- "Лидером" на шаге  $k$  назовем перестановку, задаваемую медианой Кемени для текущей выборки  $\mathcal{R}_k = \{\mathbf{r}_l\}_{l=1}^k$ .
- **Критерий останова:** отсутствие смены "лидера" на протяжении последних  $N$  шагов ( $N$  — гиперпараметр).

## Допущения (условия применимости)

- $\mathcal{R}_k \stackrel{i.i.d.}{\sim} \mathcal{D} : \exists \mathbb{E}\mathcal{D}$ ;
- $\exists!$  медиана Кемени;

## Сходимость

В силу ЦПТ расстояние от некоторой перестановки до выборки, нормированное на число экспертов, сходится к мат.ожиданию.

# Оптимальное число экспертов: эксперимент

Данные (согласованные "зашумленные" эксперты)

$$\mathcal{R}_k \stackrel{i.i.d.}{\sim} N(\boldsymbol{\mu}, \sigma^2 \mathbf{I}), \boldsymbol{\mu} = [1 \ 2 \ 3 \ 4 \ 5]^T, \sigma = 4$$

